

面向移动端的苹果叶部病虫害轻量级识别模型

刘 斌^{1,2}, 贾润昌¹, 朱先语¹, 于 聪¹, 姚卓含¹, 张海曦^{1*}, 何东健^{3,4}

(1. 西北农林科技大学信息工程学院, 杨凌 712100; 2. 农业农村部农业物联网重点实验室, 杨凌 712100; 3. 西北农林科技大学机械与电子工程学院, 杨凌 712100; 4. 陕西省农业信息感知与智能服务重点实验室, 杨凌 712100)

摘 要: 花叶病、斑点落叶病、褐斑病、白粉病、黄蚜、浅叶蛾和红蜘蛛是常见的苹果叶部病虫害, 严重影响了苹果的产量和品质。病虫害早期诊断和防治可以有效地控制病害传播, 降低损失, 保障苹果产业的健康发展。为解决现有轻量级模型无法精准识别早期苹果叶部稀疏小病斑的问题, 该研究面向资源受限的移动端设备, 提出一种轻量级识别模型 ALS-Net (Apple Leaf Net using Channel Shuffle)。在轻量化模型 (ShuffleNetV2) 的基础上, 基于深度可分离卷积和通道混洗构建 ALS 模块, 可降低模型的计算量和参数量。其次, 采用知识蒸馏策略训练模型, 进一步提高网络精度。试验结果表明, ALS-Net 的模型精度可达 99.43%, 且模型大小仅为 1.64 MB。移动端推理延迟为 55 ms, 能够有效满足实际需求, 并实现基于移动端的苹果叶部病虫害自动实时监测。

关键词: 模型; 病虫害; 苹果叶片; 通道混洗; 知识蒸馏; 轻量化; 移动端实时推理

doi: 10.11975/j.issn.1002-6819.2022.06.015

中图分类号: TP181

文献标志码: A

文章编号: 1002-6819(2022)-06-0130-10

刘斌, 贾润昌, 朱先语, 等. 面向移动端的苹果叶部病虫害轻量级识别模型[J]. 农业工程学报, 2022, 38(6): 130-139.

doi: 10.11975/j.issn.1002-6819.2022.06.015 <http://www.tcsae.org>

Liu Bin, Jia Runchang, Zhu Xianyu, et al. Lightweight identification model for apple leaf diseases and pests based on mobile terminals[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2022, 38(6): 130-139. (in Chinese with English abstract) doi: 10.11975/j.issn.1002-6819.2022.06.015 <http://www.tcsae.org>

0 引 言

苹果是中国重要的经济作物, 种植面积占世界总种植面积的 50%以上。但是苹果的生长极易受到天气、环境、病虫害等影响, 对苹果的产量、品质等造成严重损害^[1]。如果不及时发现早期病虫害并采取措施, 病害就会迅速蔓延和传播, 从而严重影响果实的正常生长, 给种植户造成严重的经济损失。为减少农药的使用, 在早期阶段快速准确识别苹果叶部病害是目前苹果种植行业亟待解决的问题。目前苹果种植过程中普遍存在的病害主要有褐斑病、斑点落叶病、白粉病和花叶病等, 存在的虫害主要有蚜虫、红蜘蛛、浅叶蛾等^[2]。

传统检测方式是通过专家经验法, 依赖专家的经验进行判断。不仅人力物力消耗较大, 且无法满足实时快速的检测需求。近年来, 基于机器学习和数字图像处理技术^[3-5], 检测方法取得了突破性进展。李昕等^[6]提出了一种结合人工免疫网络与支持向量机 (Support Vector Machine) 的多特征智能分选算法, 油茶果壳与籽粒的特

征识别率达到 97.4%。陈兵旗等^[7]基于纹理矩阵计算和小波变换原理设计算法, 通过二值图像与原图像的匹配、自动进行阈值数据处理等步骤, 得到小麦病斑的颜色特征值。Aurangzeb 等^[8]采用直方图梯度 (Histogram of Oriented Gradients)、分割分形纹理分析 (Segmentation Fractal Texture Analysis) 和局部三元模式 (Local Ternary Pattern) 对选定的马铃薯和玉米病害进行验证和分类, 识别精度达到了 92.8%。传统的机器学习方法虽然取得了显著效果。但是, 由于需要人工进行特征选择, 以及复杂的图像预处理限制了其在生产生活中的应用。

近年来, 深度学习取得了突破性进展, 在农作物病害识别领域的应用也愈加广泛^[9-11]。苏仕芳等^[12]基于迁移学习的模型训练方式提出了一种葡萄叶片病害识别模型, 准确度相较普通训练提高了 10 个百分点, 并将模型部署到移动端。徐建鹏等^[13]提出一种基于改进 Adam 优化器的 ResNet50 卷积神经网络图像识别方法, 在真实场景下分类识别准确率达到 97.33%。谢为俊等^[14]利用 Stacking 融合方法提出一种集胡萝卜缺陷种类识别和开裂缺陷分割为一体的深度多分支模型融合网络 (CS-Net), 实现了胡萝卜外观品质的量化评价和表面缺陷修整。刘洋等^[15]对 MobileNetV2 和 InceptionV3 两种轻量级卷积神经网络进行迁移学习, 将 2 种分类模型分别移植到 Android 手机端, 在葡萄病害叶片的平均识别率分别是 87.50%、88.06%。

以上研究虽取得了突破性进展, 但是上述方法难以满足移动端对早期病虫害精准识别的要求。由于轻量级

收稿日期: 2021-11-29 修订日期: 2022-03-02

基金项目: 陕西省重点研发计划项目 (2021NY-138); CCF-百度松果基金资助 (2021PP15002000); 陕西省重点研发项目 (2019ZDLNY07-0601); 全国大学生创新创业训练计划项目 (S202110712607)

作者简介: 刘斌, 博士, 副教授, 研究方向为深度学习与农作物病害诊断。

Email: liubin0929@nwsuaf.edu.cn

*通信作者: 张海曦, 博士, 讲师, 研究方向为计算机视觉、深度学习、基于图像的农作物病虫害诊断。Email: zh.haixi@nwafu.edu.cn

中国农业工程学会会员: 刘斌 (E041201274S)

模型存在参数量小、运行成本低、运算耗时少等特性，因此它能够被快速地部署到移动端设备。但是，早期苹果叶部病斑分布较为稀疏，且病斑往往呈现出面积小、形态各异等特点，因此现有的轻量级模型难以针对上述任务实现高精度分类。针对上述问题，本文提出一种改进的针对苹果早期叶部病害识别的轻量级模型 ALS-Net，在轻量化模型 ShuffleNet 的基础上，引入 ALS 模块以及特征复用机制，并使用知识蒸馏策略训练模型，最终在保证轻量化的前提下，实现对早期苹果叶部病害的准确识别。同时，本文利用 PyTorch Mobile 工具，将设计的模型部署到移动终端，实现苹果叶部病虫害的实时监测预警，以期智慧植保的发展提供新解决方案，探索新的方法。

1 苹果早期叶部病虫害数据集

1.1 图像数据集采集

苹果叶部早期病斑较小，性状不明显。例如褐斑病、红蜘蛛和斑点落叶病早期病斑较小且稀疏，为圆形或椭圆形病斑，晚期病害病斑较大、颜色较深且分布密集。由于苹果早期叶部病虫害较难发现，构建完备且高质量的苹果早期叶部病虫害图像数据库是深度学习与农业领域相结合所亟待解决的重点问题。2021 年 4 月于陕西省乾县苹果监测站，采集 7 种常见的早期苹果叶部病虫害和健康叶片作为研究对象，包括花叶病、斑点落叶病、潜叶蛾、红蜘蛛、褐斑病、黄蚜和白粉病。此外，补充了部分晚期样本来对比，如图 1 所示。



图 1 7 种常见苹果叶部病虫害和健康叶片

Fig.1 Images of seven common apple leaf diseases and pests and healthy leaves

1.2 图像数据集增强

采用更大规模的数据集对模型进行训练，可提高其泛化能力。本研究使用旋转、对称、亮度变化、移动、翻转、高斯噪声和椒盐噪声等数据增强技术对数

据集进行扩充，通过增加不同的噪声来提升模型的鲁棒性。

将采集到的数据集进行数据增强，之后按照 8:1:1 的比例划分训练集、验证集和测试集，通过测试集来验证模型的准确度，数据集各类样本统计结果如表 1 所示。

表 1 苹果叶部病虫害数据集
Table 1 Apple leaf pest and disease data set

类别名称 Class name	原始图像 Original image	增强后 Augmented			
		训练集 Training set	验证集 Validation set	测试集 Test set	总计 Total
健康 Healthy	363	3 485	436	435	4 356
花叶病 Mosaic	188	1 805	226	225	2 256
潜叶蛾 Leafminer	360	3 456	432	432	4 320
斑点落叶病 Alternaria spot	241	2 314	289	289	2 892
红蜘蛛 Spider mite	473	4 541	568	567	5 676
褐斑病 Brown spot	38	365	46	45	456
黄蚜 Aphid	121	1 162	145	145	1 452
白粉 Powdery mildew	97	931	117	116	1 164
总计 Total	1 881	18 059	2 259	2 254	22 572

2 构建苹果早期叶部病虫害识别模型

2.1 ALS-Net 整体框架

在 ShuffleNetV2 模型的基础上，构建 ALS 网络模型，其网络结构如图 2 所示。首先将病害图像的尺寸缩放为 224×224 分辨率作为模型的输入部分，之后采用大小为 3×3 的卷积核进行细节部分的特征提取。特征图像再通过 Inception 结构^[6]，采用不同大小的卷积核进行多尺度特征提取，然后通过一个最大池化来实现特征的降维，使特征图像分辨率降为原来的一半。接着通过三个相同的 ALS 模块，每个 ALS 模块中包含一个带有下采样的 Block 和无下采样的 Block。首先通过带有下采样的 Block 后特征图像分辨率减半，通道数加倍。接着通过无下采样的 Block 来进行进一步的特征提取，不改变输出的通道数。之后通过一个 1×1 的卷积核升维，在其后引入通道注意力机制^[17]。接着通过全局池化得到 8 个分类特征向量，最后由 Softmax 分类器输出最终的 8 分类结果。ALS 网络模型的内部参数如表 2 所示。


2.2 ALS 模块

2.2.1 轻量化策略

为了适应资源受限的移动终端设备，本研究构建了 ALS-Block，引入深度可分离卷积代替传统卷积来降低模型的参数量和计算量^[18]。深度可分离卷积分为深度卷积操作和逐点卷积操作。前者是进行分组卷积，在输入特征图的每个通道维度上执行单个卷积操作，后者通过执行 1×1 的标准卷积操作，将上一步的特征图在深度方向上进行加权组合，生成新的特征图。

但是，由于在分组卷积中，提取的特征信息流被分割在各个组间，组与组之间缺乏信息交流融合，降低了模型的特征提取能力，影响了模型精度。引入通道混洗 (Channel shuffle) 机制^[19]，将通道间的信息进行混洗，之后随机分配到各个通道中。在不增加计算量的前提下，

使通道间信息充分融合, 增强了模型的非线性表示能力, 缓解了分组卷积带来的精度损失。



注: Conv1 代表卷积核大小为 3×3 的卷积层; Inception 代表标准结构的 Inception; Maxpooling 代表最大池化层; Conv3 代表卷积核大小为 1×1 的卷积层; GP 代表全局池化层; FC 代表全连接层。下同。

Notes: Conv1 is a convolution kernel with a size of 3×3 ; Inception is the inception of the standard structure; Maxpooling is the maximum pooling layer; Conv3 is the convolution kernel with a size of 1×1 ; GP is the global pooling layer; FC is the full connection layer. Same below.

图 2 ALS 模型结构示意图

Fig.2 Basic structure for proposed ALS (Apple Leaf Shuffle) network

表 2 ALS-Net 的内部参数
Table 2 Internal parameters of ALS-Net

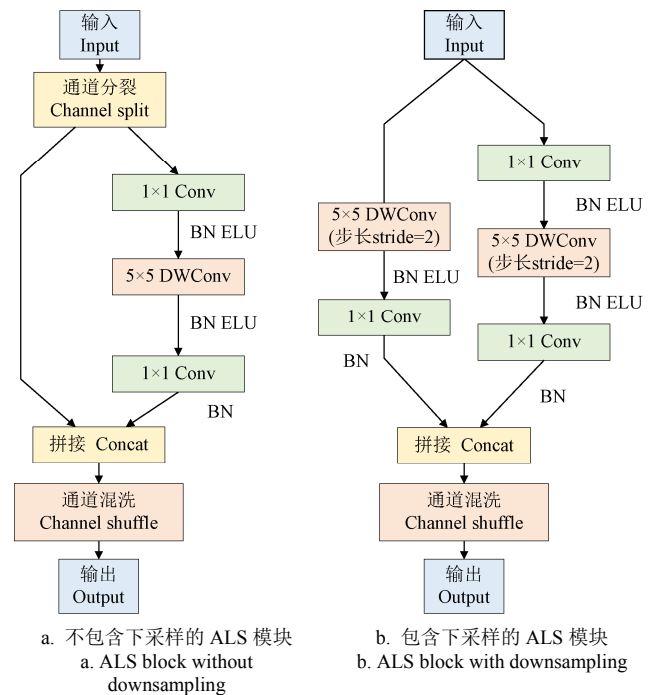
名称 Name	卷积核/步长 Kernel size/Stride	填充 Padding	输出尺寸 Output size
输入 Input	—	—	$224 \times 224 \times 3$
Conv1	$3 \times 3 / 2$	1	$112 \times 112 \times 128$
Inception	—	—	$112 \times 112 \times 128$
Maxpooling	$3 \times 3 / 2$	1	$56 \times 56 \times 128$
ALS module 1	$5 \times 5 / 2$	2	$28 \times 28 \times 48$
ALS module 2	$5 \times 5 / 2$	2	$14 \times 14 \times 96$
ALS module 3	$5 \times 5 / 2$	2	$7 \times 7 \times 192$
Conv3	$1 \times 1 / 1$	0	$7 \times 7 \times 800$
SE	—	—	$7 \times 7 \times 800$
GP	—	—	$1 \times 1 \times 800$
FC	—	—	8

注: FC 层中 Dropout 概率为 0.5。

Notes: The dropout probability in FC layer is 0.5.

ALS 模块结构如图 3 所示, 其都使用了倒残差模块, 主要用于促进多层特征信息的有效传递, 增强网络的特征提取能力。基于原始 Shuffle block 中的 3×3 卷积, 本研究将其改进为 5×5 卷积进行深度可分离卷积, 使用大卷积核会带来更大的感受野, 有利于较大病害特征的提取, 且模型也不会增加太多参数量。ShuffleNetV2 中通过堆叠 Shuffle block 个数来进行高效的局部特征提取。为了进一步实现轻量化, 本研究调整每个 ALS 模块中无下采样的 Block 数为 1 且压缩每个模块输出的通道数来进一步降低参数量和计算量。最后通过线性瓶颈层中卷积核大小为 1×1 的逐点卷积, 将通道维度进行压缩。

图 3a 显示的是没有下采样的模块。首先将输入的通道数分成两部分来分别进行卷积运算, 左分支通过残差连接来使网络的反向传播更加高效, 右分支进行倒残差模块, 接着左右分支通道进行拼接, 最后进行通道混洗来促进不同通道间信息融合。图 3b 显示的是带有下采样的模块。深度可分离卷积中的步长为 2 使分辨率减半, 左右分支拼接使通道数加倍来扩张维度, 有利于全局信息的提取。



注: 5×5 DWConv 为卷积核大小为 5×5 的深度可分离卷积; BN 为批量归一化; ELU 为激活函数。
Notes: 5×5 DWConv is a depthwise separable convolution kernel with a size of 5×5 ; BN is batch normalization; ELU is the activation function.

图 3 ALS 模块

Fig.3 ALS block

对低维度卷积层做非线性的激活函数运算, 易造成特征信息的丢失; 而通过 1×1 卷积升维后在高维度卷积层进行激活函数运算, 可以减少特征信息的丢失。因此, ALS 模块在低维度卷积层中不使用激活函数, 在其他层替换 ReLU 激活函数为 ELU 激活函数来缓解梯度消失和神经元死亡的问题。

批量归一化 (Batch Normalization, BN) 层在模型训练过程中动态调整批次大小 (batch size) 数据的均值和标准差, 以保证网络容量, 加快网络训练速度。因此在模型设计过程中, 一般需要在卷积层后加入批量归一化层来提高网络的泛化能力^[20]。


2.2.2 ELU 激活函数

由于数据的分布绝大多数是非线性的，通过引入激活函数，提高网络的非线性表达能力。 $\text{ReLU}^{[21]}$ 是神经网络中普遍使用的激活函数，特点是运算速度快、性能好，但当输入 $x < 0$ 时函数输出为 0，此时神经元处于“沉默”状态，模型的表达能力也会随之受到影响。为解决此问题，通过引入 ELU 激活函数^[22]，ELU 的定义如式 (1) 所示，ELU 中 α 为 1。ELU 为连续可微的指数平滑函数，有利于加快模型的收敛速度并提高其泛化性能。

$$f(x) = \begin{cases} x, & x > 0 \\ \alpha(e^x - 1), & x \leq 0 \end{cases} \quad (1)$$

2.2.3 通道注意力机制

在复杂环境下的苹果果园中，各个叶片交错分布，背景具有多样化，添加注意力机制来强化对病斑区域的特征提取。SE 模块的示意图如图 4 所示。首先对卷积得到的特征图进行挤压 (Squeeze)，将特征图像的分辨率压缩为 1×1 ，只保留通道维度的全局特征，再对其进行激励 (Excitation) 以学习各个通道间的关系，从而得到不同通道的权重，并与输入特征图相乘得到最终的输出特征图。SE 模块是在通道部分加入注意力机制，增加重要特征的权重，使网络有选择性的加强病虫害特征并抑制自然背景特征，从而提升网络的识别性能。



注：W、H、C 分别为特征图的宽度、高度和通道数。

Note: W, H and C are the width, height and number of channels of the feature map respectively.

图 4 压缩激励模块结构示意图

Fig.4 Structure of Squeeze and excitation block

3 模型训练过程

3.1 知识蒸馏训练策略

深度卷积神经网络在计算机视觉任务中取得了优异的表现，然而其网络结构复杂、模型较大，无法直接部署在资源受限的嵌入式设备上，也无法满足实时推理的要求。Hinton 等^[23]提出了知识蒸馏的概念，知识蒸馏用模型复杂但推理性能优越的教师网络去训练低复杂度、参数量小的学生网络，并将学生网络实际应用。知识蒸馏提供学生网络在硬标签上无法习得的软标签信息来实现知识的迁移，使学生网络的精度能够接近或超越教师网络的精度。

苹果叶部病害识别是一个细粒度图像分类任务，不同病斑之间的相似性较大，但是这些相似性不能被离散的标定出来。相比于学习单一正确标签得到的硬目标 (Hard target)，通过知识蒸馏来载入教师网络以及它的

权重文件，使学生网络能学习到除了类别之间的细微差距^[24]，这种差距是 One-hot 编码不具备的。

学生网络的 Softmax 输出层会将之前卷积层得到的预测结果转化为概率值 q 。该层会对预测结果取自然对数得到某一类的预测概率 z_i ，通过与所有类的预测概率 z_k 进行比较，生成学生网络中类的概率 q_i ，如式 (2) 所示。知识蒸馏通过对输出进行修改，增加一个温度系数 T ， T 的值越大，Softmax 函数的输出曲线越趋向于平缓，不同类别的预测概率的差距缩小。式 (3) 为教师网络的 Softmax 函数。知识蒸馏后使得教师网络输出层会产生一个软化后的概率 p_i^T 。

$$q_i = \frac{\exp(z_i)}{\sum_{k=1}^N \exp(z_k)} \quad (2)$$

$$p_i^T = \frac{\exp(v_i / T)}{\sum_{k=1}^N \exp(v_k / T)} \quad (3)$$

式中 v_i 为教师网络输出中某一类的预测概率， v_k 为所有类别的预测概率。 k 的取值从 1 到 N 。

蒸馏后的交叉熵损失 L_{soft} 及交叉熵损失 L_{hard} 计算如式 (4) 和式 (5) 所示。

$$L_{\text{soft}} = -\sum_j p_j \ln(p_i^T) \quad (4)$$

$$L_{\text{hard}} = -\sum_j c_j \ln(q_i) \quad (5)$$

式中 p_j 和 c_j 分别为教师网络和学生网络的真实标签。

如式 (6) 所示，两部分损失加权相加，得到总损失 L ， γ 为加权系数。得到损失函数并计算误差，反向传播并更新参数。知识蒸馏流程图如图 5 所示。本研究选用深层次的网络 DenseNet-161^[25]为教师网络指导训练，它将模块中的每一层连接起来，保证了网络中层与层之间最大程度的信息传输，实现了每一层的特征复用，并加强了特征的传递，一定程度上减轻了梯度消失，也显著的减少了模型参数数量。教师网络 DenseNet 的训练环境设置以及超参数设置和学生网络一致。

$$L = (1 - \gamma) L_{\text{soft}} + \gamma L_{\text{hard}} \quad (6)$$

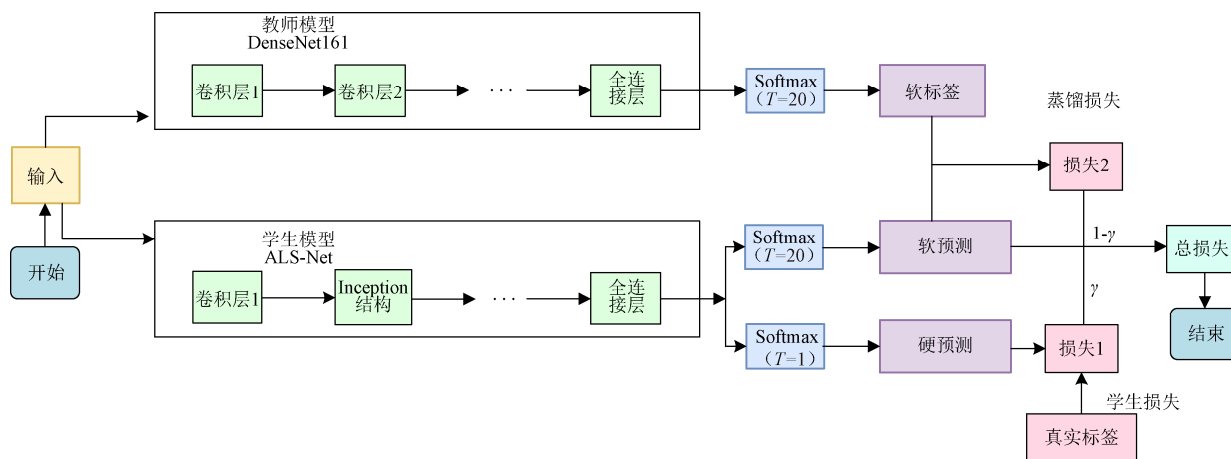
3.2 试验环境配置与超参数设置

本研究采用高性能服务器训练模型，并测试模型的准确度。高性能服务器操作系统为 Ubuntu 16.04.5，处理器 CPU 配置为 Intel(R) Xeon(R) CPU E5-2650 v4 @ 2.20 GHz，显卡配置为 GP100GL[Tesla P100 PCIe 16GB]，内存为 503 GB，硬盘大小为 2TB，Python 版本为 3.6.4，CUDA 版本为 10.0，框架版本为 PyTorch1.4.0。

模型训练的超参数设置批次大小为 32，迭代次数为 120，优化器为 Adam，学习率设置为 0.000 5，随机失活 Dropout 为 0.5，知识蒸馏时的温度系数 T 为 20，损失函数的加权系数 γ 为 0.95，损失函数为交叉熵损失函数。

移动端设备为 HUAWEI P40 Pro 5 G，处理器 CPU 为 KINRIN 990 5 G，内存为 8 G，相机分辨率为

8 192×6 144, 操作系统为 Harmony OS 2.0.0。



注: T 为温度系数, 损失函数的加权系数 γ 为 0.95。

Note: T is the temperature coefficient, and the weighting coefficient of the loss function γ is 0.95.

图 5 知识蒸馏流程图

Fig.5 Flow chart of Knowledge Distillation (KD)

4 结果与分析

4.1 模型性能对比

为进一步验证模型识别苹果叶部病虫害的效果, 在相同的试验条件下, 利用本研究构建的图像数据集, 将所设计的 ALS-Net 模型与其他卷积神经网络进行对比, 如表 3 所示。为了更加综合的评价 ALS-Net 模型的性能开销, 本文通过准确度来验证模型的泛化能力, 通过模型大小、参数量来衡量算法和模型的复杂度, 延迟用来衡量移动端实时推理的速度。

表 3 不同网络性能对比

Table 3 Performance comparison of different classic networks

模型 Model	准确度 Accuracy/%	模型大小 Model size/MB	参数量 Parameters/M	延迟 Latency/ms
AlexNet	97.54	55.69	14.59	67
VGG19	98.20	532.55	139.65	362
GoogLeNet	99.03	34.43	5.98	79
ResNet152	99.17	81.31	21.37	429
DenseNet161	99.38	102.1	26.51	496
MobileNetV2	99.14	8.71	2.23	72
MobileNetV2 (KD)	99.32	8.71	2.23	72
ShuffleNetV2 ^[27]	98.75	4.94	1.23	53
ShuffleNetV2 (KD)	98.98	4.94	1.23	53
SqueezeNetV1 ^[28]	97.04	2.83	0.74	61
SqueezeNetV1 (KD)	97.14	2.83	0.74	61
ALS-Net (本研究)	99.43	1.64	0.41	55

注: 延迟为移动端识别一张图像所需时间。KD 为采用知识蒸馏策略训练模型。

Notes: Latency is the time required for the mobile terminal to recognize a picture. KD means using knowledge distillation strategy to train the model.

经典的卷积神经网络 AlexNet、GoogLeNet 和 VGG, 它们在本数据集上的准确度较高, 如 GoogLeNet 的准确度已达到 99.03%, 但由于其模型较大, 不利于在资源受限的嵌入式设备上部署。ResNet^[26]、DenseNet 等深度卷积神经网络通过恒等映射的思想来缓解反向传播时的梯度消失问题, 但其模型参数量过大, 在移动端的推理时

间过长, 不能满足实时推理的要求。相比轻量级卷积神经网络 MobileNetV2、SqueezeNetV1 和 ShuffleNetV2, ALS-Net 在模型大小和参数量最优的情况下, 识别准确度高达 99.03%, 经过知识蒸馏后达到 99.43%, 同时移动端推理时间仅为 55 ms, 达到了在移动终端实时推理的要求。

4.2 消融试验

消融试验通常通过去除或者保留某些网络模块验证网络模型性能的提升效果, 本研究有两组消融试验, 第一组验证了扩张卷积核和调整原始 ShuffleNet 中无下采样的 Block 堆叠个数为 1 对模型准确度和参数量的影响。如表 4 所示。

相比于 3×3 大小的卷积核, 扩张为 5×5 大小后模型精度提升了 0.1 个百分点, 而模型参数量只增加了 0.07 M。此措施在有效提高模型精度的情况下略微增加参数量。相比于原始 ShuffleNet 中堆叠 Block 个数, 减少其个数后模型大小降低至之前的四分之一左右, 然而浅层的网络病害特征的提取能力有限, 模型精度大幅下降。同时使用两种 trick 后, 达到了模型准确度和大小的一个均衡状态。

第二组分别验证了 Inception 结构、注意力模块、ELU 激活函数、通道混洗机制和知识蒸馏对于模型精度的影响, 并验证全局池化对模型参数量的影响。消融试验结果如表 5 所示。

相较于表 5 中第二行仅使用普通卷积, 使用 Inception 结构, 模型大小仅提高 0.12 MB, 而模型的精度提升到了 99%, 同时由于 Inception 中多分支的卷积运算和通道拼接, 增大了 25 MB 的访问内存量。在不提升模型大小和增加内存访问量的前提下, 通道混洗技术促进了通道间信息融合, 识别准确度相比于基准模型提升了 0.3 个百分点。通道注意力机制赋予通道不同的权重, 使模型更加关注信息量大的通道特征, 有效地提高模型的精度, 但引入 SE 模块需要通过卷积和池化来压缩图片, 从而得到

通道的不同权重,所以增加了 0.09 M 的模型参数量。ELU 激活函数缓解了梯度消失和神经元死亡的问题,能够略微的提高网络的精度,但需要大量指数运算,所以在移动端增加 3 ms 的延迟。

使用知识蒸馏训练策略,采用深层的、模型参数大、准确度较高的 DenseNet161 网络作为教师网络,选取轻量化的 ALS-Net 作为学生网络来进行知识迁移。教师网络的预测中,软目标携带的信息熵高,每一类别都有相应的概率,这个概率值能够更好地展示出不同类别之间的相似性并教给学生网络。结构上两者都采用残差连接的方式来实现特征复用,模型结构相似,蒸馏效果较好。使用知识蒸馏训练策略,模型准确度提高到了 99.43%。试验结果表明,使用以上策略,能够有效地提高模型精度,以满足实际应用需求。

相较于全连接层直接将卷积层和池化层提取的高维图像特征进行降维平铺为一维向量,全局池化层先进行二维上全局最大池化,再接入 Softmax 分类器,减少了模型的训练参数,加快了模型的训练过程,且模型精度也有所上升。全局池化能有效地提取特征的全局信息,提高对白粉病、褐斑病和花叶病等病害的特征提取能力。

表 4 改进模块消融试验结果

Table 4 Ablation experimental results of improved module

K5	Small	准确度 Accuracy/%	模型大小 Model size/MB	参数量 Parameters/M
×	×	98.75	4.94	1.23
√	×	98.85	5.09	1.30
×	√	98.37	1.24	0.28
√	√	98.51	1.32	0.31

注: K5 为使用 5×5 大小的卷积核进行深度可分离卷积。Small 为调整无下采样的 Block 堆叠个数为 1。

Notes: K5 means using 5×5 convolution kernel for depthwise separable convolution. Small is to adjust the number of block stacks without down sampling to 1.

表 5 改进模型消融试验结果

Table 5 Ablation experimental results of improved model

模型 Model	准确度 Accuracy/%	模型大小 Model size/MB	延迟 Latency/ms	参数量 Parameters/M	内存 Memory/MB
ALS-Net (A)	99.43	1.64	55	0.41	121.77
A-Inception	98.63	1.52	52	0.38	96.09
A-CS	98.73	1.64	58	0.41	121.77
A-SE	98.78	1.60	54	0.32	121.42
A-GP	98.75	2.81	59	0.72	123.09
A-KD	99.03	1.64	55	0.41	121.77

注: “-” 代表在改进模型 ALS-Net 基础上不使用其后模块或策略。CS 为通道混洗策略。

Notes: “-” means improved model ALS-Net without followed module or strategy. CS is channel shuffle strategy.

4.3 激活函数对模型准确度的影响

为了进一步验证本模型网络结构的有效性,采用相同的知识蒸馏策略,选用相同的教师网络对 MobileNetV2、SqueezeNetV1 和 ShuffleNetV2 这几个轻量级网络进行训练测试,试验结果如表 6 所示。模型训练中 T 的不同取值对准确度的影响很大,本文选取 T 为 20 对不同的模型进行蒸馏试验,相比于正常训练准确度均有所提升。

为了保证试验设置的合理性、验证方法的有效性,在其他参数相同的条件下,本文选取不同的激活函数进行对比。如表 6 所示,相比于基础的 ReLU 激活函数,改进的激活函数能得到负值输出,避免神经元死亡问题,提高模型的表示能力,故识别准确度都有所提升,但由于输出范围的增大会进一步导致内存占用的提升。ELU 激活函数的准确度最优,ELU 的一部分是线性的,一部分是非线性的,指数函数微分时输出不为 0,这使网络能够向正确的方向推动权重和偏置变化,而 Leaky-ReLU 和 Param-ReLU 两部分都是线性的。

表 6 采用不同激活函数的模型试验结果

Table 6 The experiment result of models with different activation functions

激活函数 Activation function	准确度 Accuracy/%	模型大小 Model size/MB	延迟 Latency/ms	参数量 Parameters/M	内存 Memory/MB
ELU	99.03	1.64	55	0.41	121.77
ReLU	98.88	1.64	52	0.41	121.76
Param-ReLU ^[29]	98.90	1.64	53	0.41	121.77
Leaky-ReLU ^[30]	98.96	1.64	53	0.41	121.77

4.4 知识蒸馏策略对模型准确率的影响

为了验证知识蒸馏对于模型训练的影响,在其他参数相同的条件下,对比使用知识蒸馏策略的训练和一般训练的迭代曲线。由图 6 可知,两条曲线在一开始训练时伴随较大波动,在训练约 75 轮后才达到收敛。模型训练稳定之后使用知识蒸馏策略的曲线准确度基本保持在正常训练模型的上方。试验结果表明,采用知识蒸馏的训练策略可在不增加模型参数的情况下显著地提高模型在训练集上的准确率,且加快训练时的收敛速度。

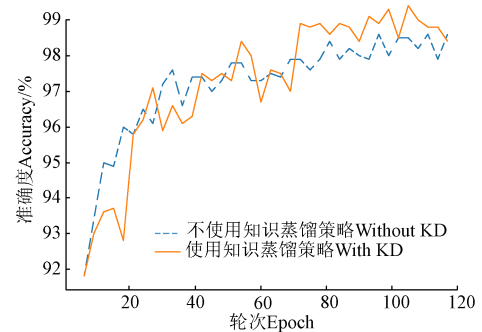


图 6 模型训练迭代曲线

Fig.6 Model training iteration curve

4.5 调和平均数的选取及模型性能综合评价

在正、负样本不平衡的情况下,仅用准确率这个指标来评定模型的识别性能是不全面的,因此本研究采用查准率 P 、查全率 R 、 F_β 得分来进一步衡量 ALS-Net 模型的识别性能^[31]。

查准率和查全率一般相互矛盾,常用 $F1$ 调和平均数来对模型进行分析,但在实际应用中,对两者的重视程度有所不同, F_β 能表达出对两种指标的不同偏好,确定组合分数中精度权重的参数 $\beta < 1$ 时对查准率有更大影响, F_β 的定义如式 (7) 所示。

$$F_{\beta} = \frac{(1 + \beta^2) \cdot P \cdot R}{(\beta^2 \cdot P) + R} \quad (7)$$

为了能对果树病虫害进行精准识别,本研究取 β 为 0.5, 指标更偏向于查准率。ALS-Net 在各个病害上的查准率、查全率和 F_{β} 得分如表 7 所示。

表 7 模型性能的评价指标

Table 7 Evaluation index of model performance

类别 Class	查准率 Precision	查全率 Recall	F_{β} 得分 F_{β} score
健康 Healthy	1.000	1.000	1.000
花叶病 Mosaic	0.978	0.982	0.979
潜叶蛾 Leafminer	1.000	1.000	1.000
斑点落叶 Alternaria spot	0.972	0.966	0.970
红蜘蛛 Spider mite	1.000	1.000	1.000
褐斑病 Brown spot	1.000	1.000	1.000
黄蚜 Aphid	0.993	0.993	0.993
白粉病 Powdery mildew	0.987	0.987	0.987

混淆矩阵常用来可视化地评估模型的性能优劣。图 7 给出了 7 种病虫害和健康类别的分类混淆矩阵。由图 7 可知, 451 张花叶病叶片中有 443 张被正确识别, F_{β} 得分为 0.979; 326 张斑点落叶病叶片中有 315 张被正确识别, F_{β} 得分为 0.97; 290 张蚜虫病叶片中有 288 张被正确识别, F_{β} 得分为 0.993; 232 张白粉病叶片中有 229 张被正确识别, F_{β} 得分为 0.987; 其余的 4 种均全部正确识别, F_{β} 得分为 1.000。

此外, 有 7 张花叶病被识别成了斑点落叶病, 有 8 张斑点落叶病被识别成了花叶病。分析可知, 在早期病害中病斑较小且分散较稀疏, 斑点落叶病形态为红褐色圆形或椭圆形病斑, 而花叶病病斑形状与其相似且颜色较黄, 因此两者识别时容易混淆, 故识别准确率较低。其他 5 种病虫害和健康类别的识别结果都较为准确。这表明本文提出的模型具有较好的识别性能和鲁棒性, 可以高效地应用于复杂的自然环境中。

斑点落叶病 Alternaria spot A	315	1	0	7	1	0	0	0
黄蚜 Aphid B	1	288	0	0	1	0	0	0
褐斑病 Brown spot C	0	0	91	0	0	0	0	0
花叶病 Mosaic D	8	1	0	443	1	0	0	0
白粉病 Powdery mildew E	2	0	0	1	229	0	0	0
健康 Health F	0	0	0	0	0	871	0	0
潜叶蛾 Leafminer G	0	0	0	0	0	0	864	0
红蜘蛛 Spider mite H	0	0	0	0	0	0	0	1118
	A	B	C	D	E	F	G	H

真实标签 True labels

图 7 混淆矩阵

Fig.7 Confusion matrix

4.6 移动终端模型部署实现

为了使最终的卷积神经网络模型更加快捷智能地进

行病害检测, 将轻量级模型部署在移动端应用, 安装到华为 P40 Pro 移动手机上。部署流程图如图 8 所示。

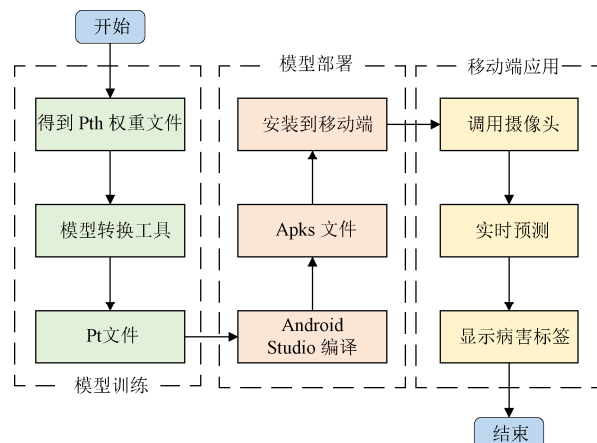


图 8 部署流程图

Fig.8 Deployment flowchart

首先将模型训练得到的 pth 权重文件转换为 C++ 可调用的 pt 文件, 再使用 Android Studio 编译成 apks 文件并安装到手机上, 移动端可以利用手机自带的相机拍摄病害图片并进行预测, 模型识别一张病虫害图片的延迟仅为 55 ms, 可以满足实际生产中的应用。移动终端检测界面如图 9 所示。




图 9 移动终端识别界面

Fig.9 Mobile terminal recognition interface

5 结论

为了在移动端准确快速地诊断苹果叶部病害, 本研究针对早期叶部病虫害病斑稀疏, 形态各异等特点, 提出一种改进的针对苹果早期叶部病害识别的轻量级模型 ALS-Net。首先通过数字图像处理数据技术对原始数据集进行增强, 有效地提高了模型的鲁棒性。然后, 基于深度可分离卷积和通道混洗技术构建了 ALS 模块并采用知识蒸馏策略来保证模型的高精度, 对试验结果进行分析, 得出以下结论:

1) ALS-Net 模型大小为 1.64 MB, 识别准确度达到 99.43%, 在减少模型参数和计算量的同时使其性能保持

在一个较高水平, 可以部署在资源受限的移动端。

2) 通过模型训练曲线可以看到, 在相同试验条件下, 采用知识蒸馏策略的训练方式显著提高模型的识别准确率, 且加快训练时的收敛速度。

3) 基于安卓开发, 最后将模型部署在移动终端上进行病虫害识别, 移动端推理时间仅为 55 ms, 满足实时推理的需求。

本研究提出的 ALS-Net 实现了模型的高准确度和轻量化, 且满足移动端实时推理的需求, 在苹果叶部病虫害识别方面具有优异性能, 为早期苹果叶部病害识别研究提供了新思路, 下一步将尝试将模型移植到智能巡检机器人上, 并实现农药的精准喷洒, 从而进行智能化农作物病虫害监测和防治。

[参 考 文 献]

- [1] 赵朋, 刘刚, 李民赞, 等. 基于 GIS 的苹果病虫害管理信息系统[J]. 农业工程学报, 2006, 22(12): 150-154.
Zhao Peng, Liu Gang, Li Minzan, et al. Management information system for apple diseases and insect pests based on GIS[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2006, 22(12): 150-154. (in Chinese with English abstract)
- [2] Sun H, Xu H, Liu B, et al. MEAN-SSD: A novel real-time detector for apple leaf diseases using improved light-weight convolutional neural networks[J]. Computers and Electronics in Agriculture, 2021, 189:106379.
- [3] 马慧琴, 黄文江, 景元书, 等. 基于 AdaBoost 模型和 mRMR 算法的小麦白粉病遥感监测[J]. 农业工程学报, 2017, 33(5): 162-169.
Ma Huiqin, Huang Wenjiang, Jing Yuanshu, et al. Remote sensing monitoring of wheat powdery mildew based on AdaBoost model combining mRMR algorithm[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2017, 33(5): 162-169. (in Chinese with English abstract)
- [4] 李佳, 吕程序, 苑严伟, 等. 快速傅里叶变换结合 SVM 算法识别地表玉米秸秆覆盖率[J]. 农业工程学报, 2019, 35(20): 194-201.
Li Jia, Lü Chengxu, Yuan Yanwei, et al. Automatic recognition of corn straw coverage based on fast Fourier transform and SVM[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2019, 35(20): 194-201. (in Chinese with English abstract)
- [5] 张宏鸣, 陈丽君, 刘雯, 等. 基于 Stacking 集成学习的夏玉米覆盖度估测模型研究[J]. 农业机械学报, 2021, 52(7): 195-202.
Zhang Hongming, Chen Lijun, Liu Wen, et al. Estimation of summer corn fractional vegetation coverage based on stacking ensemble learning[J]. Transactions of the Chinese Society for Agricultural Machinery, 2021, 52(7): 195-202. (in Chinese with English abstract)
- [6] 李昕, 陈泽君, 李立君, 等. 基于偏好免疫网络和 SVM 算法的油茶果多特征识别[J]. 农业工程学报, 2020, 36(22): 205-213.
Li Xin, Chen Zejun, Li Lijun, et al. Recognition of *Camellia* multi-features based on preference artificial immune network and support vector machine[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2020, 36(22): 205-213. (in Chinese with English abstract)
- [7] 陈兵旗, 郭学梅, 李晓华, 等. 基于图像处理的小麦病害诊断算法[J]. 农业机械学报, 2009, 40(12): 190-195.
Cheng Bingqi, Guo Xuemei, Li Xiaohua, et al. Algorithm of diseased wheat[J]. Transactions of the Chinese Society for Agricultural Machinery, 2009, 40(12): 190-195. (in Chinese with English abstract)
- [8] Aurangzeb K, Akmal F, Khan M A, et al. Advanced machine learning algorithm based system for crops leaf diseases recognition[C]//Riyadh: IEEE. Proceedings of the Conference on Data Science and Machine Learning Applications(CDMA). 2020: 146-151.
- [9] 鲍文霞, 吴德钊, 胡根生, 等. 基于轻量级残差网络的自然场景水稻害虫识别[J]. 农业工程学报, 2021, 37(16): 145-152.
Bao Wenxia, Wu Dezhao, Hu Gensheng, et al. Rice pest identification in natural scene based on lightweight residual network[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2021, 37(16): 145-152. (in Chinese with English abstract)
- [10] 翟肇裕, 曹益飞, 徐焕良, 等. 农作物病虫害识别关键技术研究综述[J]. 农业机械学报, 2021, 52(7): 1-18.
Zhai Zhaoyu, Cao Yifei, Xu Huanliang, et al. Review of key techniques for crop disease and pest detection[J]. Transactions of the Chinese Society for Agricultural Machinery, 2021, 52(7): 1-18. (in Chinese with English abstract)
- [11] 黄建平, 陈镜旭, 李克新, 等. 基于神经结构搜索的多种植物叶片病害识别[J]. 农业工程学报, 2020, 36(16): 166-173.
Huang Jianping, Chen Jingxu, Li Kexin, et al. Identification of multiple plant leaf diseases using neural architecture search[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2020, 36(16): 166-173. (in Chinese with English abstract)
- [12] 苏仕芳, 乔焰, 饶元. 基于迁移学习的葡萄叶片病害识别及移动端应用[J]. 农业工程学报, 2021, 37(10): 127-134.

- Su Shifang, Qiao Yan, Rao Yuan. Recognition of grape leaf diseases and mobile application based on transfer learning[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2021, 37(10): 127-134. (in Chinese with English abstract)
- [13] 徐建鹏, 王杰, 徐祥, 等. 基于 RAdam 卷积神经网络的水稻生育期图像识别[J]. 农业工程学报, 2021, 37(8): 143-150.
Xu Jianpeng, Wang Jie, Xu Xiang, et al. Image recognition for different developmental stages of rice by RAdam deep convolutional neural networks[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2021, 37(8): 143-150. (in Chinese with English abstract)
- [14] 谢为俊, 魏硕, 郑招辉, 等. 深度多分支模型融合网络的胡萝卜缺陷识别与分割[J]. 农业工程学报, 2021, 37(2): 177-186.
Xie Weijun, Wei Shuo, Zheng Zhaohui, et al. Classification and segmentation of defect carrots using deep multi-branch models fusion network[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2021, 37(2): 177-186. (in Chinese with English abstract)
- [15] 刘洋, 冯全, 王书志. 基于轻量级 CNN 的植物病害识别方法及移动端应用[J]. 农业工程学报, 2019, 35(17): 194-204.
Liu Yang, Feng Quan, Wang Shuzhi. Plant disease identification method based on lightweight CNN and mobile application[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2019, 35(17): 194-204. (in Chinese with English abstract)
- [16] Szegedy C, Liu W, Jia Y, et al. Going deeper with convolutions[C]//Boston: IEEE. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2015: 1-9.
- [17] Hu J, Shen L, Sun G. Squeeze-and-excitation networks[C]//Salt Lake City: IEEE. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2018: 7132-7141.
- [18] Sandler M, Howard A, Zhu M, et al. Mobilenetv2: Inverted residuals and linear bottlenecks[C]//Salt Lake City: IEEE. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2018: 4510-4520.
- [19] Zhang X, Zhou X, Lin M, et al. Shufflenet: An extremely efficient convolutional neural network for mobile devices[C]//Salt Lake City: IEEE. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2018: 6848-6856.
- [20] Ioffe S, Szegedy C. Batch normalization: Accelerating deep network training by reducing internal covariate shift[C]//Lille: IEEE. Proceedings of the International Conference on Machine Learning, 2015: 448-456.
- [21] Glorot X, Bordes A, Bengio Y. Deep sparse rectifier neural networks[C]//Ft. Lauderdale: IEEE. Proceedings of the fourteenth international Conference on Artificial Intelligence and Statistics, 2011: 315-323.
- [22] Unterthiner T, Hochreiter S. Fast and accurate deep network learning by exponential linear units (ELUs)[C]//Puerto Rico: IEEE. Proceedings of the International Conference on Learning Representations, 2016: 1-14.
- [23] Hinton G, Vinyals O, Dean J. Distilling the knowledge in a neural network[J]. Computer Science, 2015, 14(7): 38-39.
- [24] 倪建功, 李娟, 邓立苗, 等. 基于知识蒸馏的胡萝卜外观品质等级智能检测[J]. 农业工程学报, 2020, 36(18): 181-187.
Ni Jiangong, Li Juan, Deng Limiao, et al. Intelligent detection of appearance quality of carrot grade using knowledge distillation[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2020, 36(18): 181-187. (in Chinese with English abstract)
- [25] Huang G, Liu Z, Van Der Maaten L, et al. Densely connected convolutional networks[C]//Honolulu: IEEE. Proceedings of the IEEE conference on Computer Vision and Pattern Recognition, 2017: 4700-4708.
- [26] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]//Las Vegas: IEEE. Proceedings of the IEEE conference on Computer Vision and Pattern Recognition, 2016: 770-778.
- [27] Ma N, Zhang X, Zheng H T, et al. Shufflenet v2: Practical guidelines for efficient cnn architecture design[C]//Munich: IEEE. Proceedings of the European Conference on Computer Vision, 2018: 116-131.
- [28] Iandola F N, Han S, Moskewicz M W, et al. SqueezeNet: AlexNet-level accuracy with 50x fewer parameters and < 0.5 MB model size[C]. Munich: IEEE. Proceedings of the International Conference on Learning Representations, 2017: 207-212.
- [29] J. Xu, Z. Li, B. Du, M. Zhang and J. Liu, Reluplex made more practical: Leaky ReLU[C]//Newcastle: IEEE. Symposium on Computers and Communications, 2020: 1-7, doi: 10.1109/ISCC50000.2020.9219587.
- [30] He K, Zhang X, Ren S, et al. Delving deep into rectifiers: Surpassing human-level performance on imagenet classification[C]//Santiago: IEEE. Proceedings of the IEEE international Conference on Computer Vision. 2015: 1026-1034.
- [31] 周志华. 机器学习[M]. 北京: 清华大学出版社, 2016:

30-33.

Lightweight identification model for apple leaf diseases and pests based on mobile terminals

Liu Bin^{1,2}, Jia Runchang¹, Zhu Xianyu¹, Yu Cong¹, Yao Zhuohan¹, Zhang Haixi^{1*}, He Dongjian^{3,4}

(1. College of Information Engineering, Northwest A&F University, Yangling 712100, China; 2. Key Laboratory of Agricultural Internet of Things, Ministry of Agriculture and Rural Affairs, Yangling 712100, China; 3. College of Mechanical and Electronic Engineering, Northwest A&F University, Yangling 712100, China; 4. Shaanxi Key Laboratory of Agricultural Information Perception and Intelligent Service, Yangling 712100, China)

Abstract: Apple has been one of the most popular cash crops for the development of the agricultural economy. Seven common diseases have posed a serious threat to the yield and quality of apples, including the Mosaic, Alternaria spot, Brown spot, Powdery mildew, Aphid, Leafminer and Spider mite pests of plant leaves. Early diagnosis and control of diseases and pests can greatly contribute to preventing the spread and reducing losses in the apple industry. However, the current lightweight models cannot accurately identify the sparse small lesions in early apple leaves. In this study, a lightweight recognition model, ALS-Net (Apple Leaf Net using channel shuffle) was proposed for the resource-constrained mobile terminals. The specific procedure was as follows: 1) Firstly, 1 881 images of diseased and healthy apple leaves were collected in Qian County, Shaanxi Province in China. Digital image processing was conducted to enhance the original images, particularly for the generalization and robustness of the model. 2) Secondly, the ALS module was constructed using depth-wise separable convolution and channel shuffle technology. The calculations and parameters of the model were significantly reduced, compared with the traditional convolution network. The channel shuffle technology fully shuffled the information between channels, and then randomly assigned it to each channel. As such, the loss of accuracy was alleviated in group convolution. The Inception structure was introduced into the model for the multi-scale feature extraction. The channel attention was selected to strengthen the disease features in the network, while suppressing the natural background. The Exponential Linear Unit (ELU) was selected as the activation function to accelerate the convergence speed of the model. 3) The knowledge distillation strategy was used to train the model, providing the soft label information that the student model cannot learn on the hard label to realize the transfer of knowledge. The accuracy of the student model was approached or exceeded the accuracy of the teacher model. DenseNet-161 with high accuracy was selected as the teacher model, and the ALS-Net was the student model. A high-performance server was utilized to train the model for the generalization of the model. The experimental results were as follows. 1) The comparative experiment showed that the accuracy of ALS-Net reached 99.43%, which was higher than that of classical CNNs, such as AlexNet and ResNet, and the size of the model was only 1.64 MB, which was lower than that of lightweight CNNs, such as MobileNetV2 and ShuffleNetV2. 2) There were two sets of ablation experiments. The first verified the effects of expanding the convolution kernel to adjust the number of blocks on the model accuracy and parameter number. The second verified the effects of Inception structure, attention module, ELU activation function, and channel shuffle on the accuracy of the model. 3) The training of knowledge distillation strategy significantly improved the recognition accuracy, further accelerating the convergence speed during training. 4) Using PyTorch Mobile, the model was deployed on HUAWEI P40 Pro 5G mobile terminal for real-time inference. The inference delay of the mobile terminal was 55 ms, fully meeting the requirements of practical application. The automatic recognition of apple leaf diseases and pests was realized on the mobile terminal. The finding can provide an insightful idea for the early diagnosis of apple leaf diseases and pests.

Keywords: models; pests and diseases; apple leaves; channel shuffle; knowledge distillation; lightweight; real-time inference on mobile terminal